



中山大學

SUN YAT-SEN UNIVERSITY

多模态文档理解与检索问答系统

多模态文档理解与检索问答系统结题报告

姓 名 陈宝怡 孙韵淇 吴承徽

学 号 23336029 23336215 23336247

学 院 计算机学院

专 业 计算机科学与技术

2026 年 6 月 17 日

摘 要

本项目围绕教育学习、学术研究及日常办公场景中基于复杂文档信息的多模态问答任务，设计并实现了一套以结构化解析、块级索引、视觉辅助生成为核心的多模态检索增强生成系统。项目的初始目标是验证“文档结构感知 + 多模态检索增强”能否有效缓解传统纯文本问答系统在复杂页面理解、长文档检索与证据定位方面的局限；而在具体实现与实验推进过程中，我们进一步发现，真正决定系统结论是否可信的关键，不仅在于模型或模块是否足够复杂，更在于评测对象、索引对象与任务定义三者是否严格对齐。

围绕这一认识，我们完成了三方面工作。其一，构建了从数据标准化、MinerU 页面解析、块级语义切分、轻量索引构建、后端问答服务到 benchmark 评测的完整工程闭环。其二，对原始 DocVQA val 数据集构建 unique-docpage-100 子集，固定评测清单以及与该清单严格对齐的重建索引语料。其三，在修复评测协议后重新审视视觉信息在系统中的作用位置，证明视觉信号在当前项目条件下更适合作为生成阶段的门控辅助，而不宜默认前置为检索阶段的强融合信号。

实验结果表明：在原始 val-100 评测基准上，以视觉稠密融合为核心的历史最佳检索线 (exp5_densefusion_w045) 仅取得 Hit@5=0.51、Citation@1=0.13；而在修复后的 unique-docpage-100 页级评测基准及其对应的重建索引语料上，以文本优先检索、题型感知和查询图像感知重排为核心的检索主线 (stronger_qia_v6) 达到 Hit@5=0.95、Precision@5=0.196、Citation@1=0.91，进一步加入门控视觉辅助后的端到端主线 (stronger_qia_visualassist_gated_v2) 达到 Hit@5=0.95、Citation@1=0.90、EM=0.87、ANLS=0.962800、Token-F1=0.951780。研究结果说明，在课程规模的多模态文档问答系统中，稳定的文本优先检索、合理的页级评测构造以及题型敏感的视觉辅助机制，比单纯堆叠更多多模态融合模块，更能带来可信、可解释且可复现的系统提升。

目录

1	引言	1
1.1	研究背景	1
1.2	研究目标与研究问题	1
2	相关工作	1
2.1	多模态文档理解与文档 RAG	1
2.2	结构感知切分与本文定位	2
3	系统设计与实现	2
3.1	总体设计思路	2
3.2	数据标准化、MinerU 解析与块优先结构	3
3.3	索引构建与文本优先检索主线	4
3.4	服务接口、证据组织与引用返回	5
3.5	从检索期视觉融合到生成期门控视觉辅助	6
4	实验设计	6
4.1	数据集与评测对象	6
4.2	指标体系	7
4.3	对比实验设置	7
5	实验诊断与策略调整	8
5.1	评测协议修复与 rebuilt corpus	8
5.2	从检索期视觉融合到生成期视觉辅助	8
6	实验结果与分析	8
6.1	评测基准修复	8
6.2	文本优先排序	9
6.3	视觉信息前置到检索阶段	10
6.4	视觉信息放到生成阶段后	10
6.5	模型的视觉能力不是主要瓶颈	11
6.6	本章小结：各模块的真实贡献与代价	12
7	讨论	12
7.1	相比开题设想的真实变化	12
7.2	本项目最值得保留的研究经验	12
8	局限性与后续工作	13

9 结论

13

1 引言

1.1 研究背景

在教学、科研与办公场景中的文档往往同时包含文本、表格、图像、公式与复杂版面结构。对于这类文档，用户不仅希望系统能够答对问题，还希望系统能够定位到对应页面、证据区域与关键短语，从而保证回答可追溯、可核验。

传统纯文本切分方案容易丢失标题、页码、图表边界等非线性信号；而直接依赖整页视觉推理又难以稳定解决“先找哪一页、再读哪一块”的问题。因此，文档问答更适合采用“结构化解析 + 块级检索 + 引用式生成”的路线。本文关注的核心问题有两个：视觉信息应优先作用于检索阶段还是生成阶段，以及实验结论是否建立在与任务目标一致的评测协议之上。

1.2 研究目标与研究问题

本研究旨在构建一个面向课程文档的多模态问答系统，实现复杂页面的结构化解析、块级证据检索、可追溯回答生成与标准化实验评测。围绕这一目标，本文聚焦三个研究问题：

1. 原始 DocVQA val first-100 上的性能平台期，究竟来自模型与检索能力不足，还是来自 benchmark 定义偏差。
2. 在当前课程项目的数据规模与系统架构下，视觉信息最有效的接入位置究竟是检索阶段，还是生成阶段。
3. 在修复评测协议后，系统剩余错误的主要来源究竟是普通排序噪声，还是 query grounding、OCR 表示与版面理解的更深层缺口。

围绕这些问题，本文构建了从页面解析、索引构建、证据召回、回答生成到 citation 返回的完整链路，并在实验中逐步将系统主线收敛为“文本优先检索 + 生成阶段视觉辅助 + 与任务一致的评测协议”。

2 相关工作

2.1 多模态文档理解与文档 RAG

多模态大模型为文档理解提供了新的技术基础。与仅处理线性文本的语言模型相比，视觉语言模型能够同时利用页面图像与文字内容，因此在标题、徽标、页码、表单与局部短文本识别等任务上具有明显优势。但多模态能力并不自动等价于可用的文档检索系统：若直接依赖整页视觉推理，仍然难以稳定解决“先找页、再读块”的证据组织问题。

RAG 通过”外部检索 + 条件生成”缓解了纯生成模型在长文档和外部知识利用上的限制，已经成为文档问答的重要技术路线。传统文本 RAG 检索稳定、成本可控、可解释性较强，但其索引对象通常是线性文本片段，难以显式保留页面结构与局部视觉信息。近年来，多模态 RAG 进一步将视觉路径引入检索与生成，说明文档问答既不能简单退回纯文本方案，也不宜完全依赖整页视觉推理，而应在检索粒度、语义保持与可追溯性之间寻找更稳健的平衡。

2.2 结构感知切分与本文定位

除模型能力之外，文档问答中的另一个关键问题在于切分与证据表示。若切分过程不能保留版面结构与阅读顺序，即便检索命中了”相关文本”，也未必命中了”完整证据”。因此，结构感知切分与块级证据表示是连接页面解析、检索重排与 citation 返回的关键中间层。

本文采用”块优先”思路，将页面解析结果视为主索引对象，并保留 `chunk_id`、`page_no`、`bbox`、`source_ref` 等回溯字段，以支撑后续检索、重排、引用返回与误差分析。与现有工作相比，本文更关注两个工程问题：其一，多模态信息并不一定越早介入越好；其二，若评测协议与真实任务目标不一致，模型比较结论也会发生系统性偏移。基于此，本文将系统主线定位为以文本优先检索为核心、以生成阶段门控视觉辅助为补充，并通过 benchmark 修复保证结论的有效性。

3 系统设计与实现


3.1 总体设计思路

针对开题报告中提出的”语义丢失”与”长文档检索困难”两类核心问题，本文最终采用”结构化解析 + 块级表示 + 文本优先检索 + 视觉辅助生成”的总体路线。与开题阶段偏重”双路径 RAG + 晚融合”的设想相比，结题阶段最大的变化不在于模块数量的增减，而在于系统内部主次关系的重新排序：文本检索被确立为主证据排序机制，视觉信息则更多承担局部消歧与回答补偿的角色。

系统整体可划分为四个阶段：

1. 数据标准化与页面解析。
2. 块级语义对象构建与索引生成。
3. 证据召回、重排与组织。
4. 回答生成、citation 返回与离线评测。

这一设计的核心原则是：任何生成结果都应尽量能够回到具体页面与具体块，任何实验结论都应尽量能够回到明确的索引对象与评测协议。



文本优先检索是稳定的主证据路径；视觉辅助在生成阶段有效，但其触发策略仍依赖任务设计与后续优化。

图 1: 系统整体流程图。该流程覆盖数据标准化、页面解析、块级索引、检索重排、视觉辅助生成与评测闭环。

3.2 数据标准化、MinerU 解析与块优先结构

数据入口由 `scripts/01_prepare_datasets.py`、`scripts/06_run_mineru.py` 与 `scripts/07_parse_and_chunk.py` 共同构成。前者负责将 DocVQA、ChartQA 等评测集统一标准化为 JSONL；然后将页面图片或 PDF 输入交给 MinerU，得到归一化的页面块；后者负责将解析结果转换为 `documents.jsonl` 与 `chunks.jsonl` 两类产物。

其中，`documents.jsonl` 主要记录文档级与样本级元信息，不直接作为检索对象；真正进入索引的是 `chunks.jsonl` 中的块级对象。每个块至少保留以下字段：`chunk_id`、`document_id`、`block_id`、`page_no`、`bbox`、`source_ref`、`source_path`、`image_path` 与 `metadata`。项目在后期放弃将 benchmark 问题文本作为默认检索对象的做法，仅将其保留为早期 smoke test 所需的可选调试机制。这一转变意味着系统从记住问题走向读取页面，从而保证检索对象与真实任务对象保持一致。

为便于明确文档级对象与块级对象的职责边界，本文将两类核心数据结构概括如表 1 所示。

表 1: 核心数据结构说明

对象	角色定位	核心字段	进入索引
<code>documents.jsonl</code>	文档级父对象	<code>document_id</code> , <code>dataset</code> , <code>split</code> , <code>source_type</code> , <code>source_path</code> , <code>image_path</code> , <code>page_no/page_count</code> , <code>question</code> , <code>answers</code> , <code>metadata</code>	否
<code>chunks.jsonl</code>	块级证据对象	<code>chunk_id</code> , <code>document_id</code> , <code>block_id</code> , <code>block_index</code> , <code>part_index</code> , <code>chunk_type</code> , <code>text</code> , <code>page_no</code> , <code>bbox</code> , <code>source_ref</code> , <code>image_path</code> , <code>metadata</code>	是

表 1 表明, 本文并不把文档级记录与检索级记录混为一谈。documents.jsonl 负责回答”这是什么文档、来自哪里、对应什么评测样本”, 而 chunks.jsonl 负责回答”哪一段证据应进入索引、应如何被召回、以及应如何回溯到原页面区域”。

上述数据构建过程可抽象为算法 1。

Algorithm 1 文档解析与块级切分流程

Require: 原始输入 x (PDF、页面图像或标准化评测样本)

Ensure: 文档级记录 d , 与块级证据集合 $\mathcal{C}$

- 1: 若 x 来自公开数据集, 则先标准化为统一评测样本格式
 - 2: 提取 x 对应的页面图像或 PDF 路径
 - 3: 调用 MinerU 对页面进行结构化解析, 得到语义块集合 $\mathcal{B}$
 - 4: 构建文档级记录 d , 写入 document_id、source_path、image_path、page 信息与 metadata
 - 5: 初始化块级集合 $\mathcal{C} \leftarrow \emptyset$
 - 6: **for** 每个语义块 $b \in \mathcal{B}$ **do**
 - 7: 规范化块类型、页码、bbox、image_path 与原始解析字段
 - 8: 若 b 的文本长度 $\leq \text{max_chars_per_chunk}$, 则生成一个 chunk c
 - 9: 否则在 b 内部按滑窗切分, 生成多个 part, 并共享同一 block_id
 - 10: 若 b 为 figure/table/formula/page_image 且文本为空, 则补充占位文本
 - 11: 为每个 c 写入 chunk_id、document_id、block_id、page_no、bbox、source_ref、metadata
 - 12: 将 c 加入 $\mathcal{C}$
 - 13: **end for**
 - 14: **return** d 与 $\mathcal{C}$
-

3.3 索引构建与文本优先检索主线

scripts/08_build_indexes.py 负责基于块级对象构建本地轻量索引。当前主线索引主要包含三类对象: 一是以 doc_store.json、postings.json 等为核心的稀疏文本索引; 二是 visual_store.json 形式的视觉元数据索引; 三是部分实验中使用的视觉描述符存储与向量文件。

核心检索逻辑位于 src/models/retrieval.py。从机制上看, 系统采用”两阶段检索”思路: 第一阶段先用轻量的文本相似度方法, 从全部块级证据中快速筛出一小批候选; 第二阶段再对这些候选进行更细致的重排判断。这样设计的原因在于, 文档问答并不只是”找词最像的文本”, 而是要在大量页面块中找出”最可能真正回答当前问题的证据块”。

在重排阶段, 系统不再把所有问题都当作同一类文本匹配任务处理, 而是显式区分不同题型对证据形态的依赖差异。对于标题、页眉、徽标、页码等问题, 系统会更偏好

短标题块、页面顶部块或具有明显版面标记的块；对于表格与图表问题，系统会更重视包含结构化数值信息的文本块；对于明显缺乏信息量的通用占位块、噪声块或与问题仅存在表面重合的块，则给予额外惩罚。换言之，系统试图学习的不是”哪段话和问题最像”，而是”哪类证据在当前题型下最有可能是正确证据”。

后期优化中的一个关键改动，是在更强检索配置下，先削弱问题中低信息词对初筛结果的影响，再进行候选排序。这样做的背景是：我们在误差分析中发现，一些由调试机制生成的 synthetic chunk 会重复题干表述，因此很容易仅凭表面词汇重叠获得较高分数，进而压制真正来自页面内容的证据块。通过降低这类低信息词和题干回声的支配作用，系统能够把注意力更多放在实体词、结构词和页面内容本身上。其结果并不是简单地”多加几条规则”，而是让检索过程更接近文档问答任务真正关心的目标，即从原始页面中定位可信、可回溯且与当前问题语义对应的证据。

对应的主检索流程可概括为算法 2。

Algorithm 2 文本优先检索与重排流程

Require: 用户问题 q ，索引语料 $\mathcal{I}$ ，返回条数 k

Ensure: 排序后的证据列表 $\mathcal{E}$

- 1: 对 q 进行分词，得到 query tokens
 - 2: 若 rerank_profile = stronger，则过滤低信息 stopwords
 - 3: 基于稀疏表示在 $\mathcal{I}$ 中计算 chunk 级初始相似度分数
 - 4: 选取前 N 个候选块构成候选池 $\mathcal{P}$
 - 5: **for** 每个候选块 $p \in \mathcal{P}$ **do**
 - 6: 判断 q 是否属于 title / heading / logo / page number / table / chart 等题型
 - 7: 对短标题块、页码样式块、结构化表格文本给予奖励
 - 8: 对低信息噪声块、通用占位块或错误词面回声块给予惩罚
 - 9: 若启用 query-image-aware rerank，则对 deictic/layout 问题追加页面级辅助重排
 - 10: **end for**
 - 11: 合并基础分数与重排增益，得到最终分数
 - 12: 按最终分数降序排序，并截取 top- k 结果
 - 13: **return** $\mathcal{E}$
-

3.4 服务接口、证据组织与引用返回

src/serving/api.py 提供完整的后端服务闭环。系统通过 /api/v1/chat 接收 query、上下文与可选图片输入，调用 LocalTextRetriever 召回证据块，再将证据组织为生成提示词，最后由视觉语言模型生成回答并返回 citation。citation 至少包含 chunk_id、source、page、snippet 等字段，并通过 source_ref 保留到原始页面与区域的回溯路径。

3.5 从检索期视觉融合到生成期门控视觉辅助

项目关于视觉路径的实现经历了明显演化。早期思路倾向于在检索阶段直接进行视觉稠密融合，希望利用页面图像的全局相似性提升召回质量；相应地，`benchmark.py` 中也实现了视觉融合与 `query-image-aware rerank` 等实验路径。然而，后续实验表明，在页面布局相近、标题模板重复、通用视觉元素较多的课程文档场景中，视觉描述符容易把“看起来相似”但证据并不正确的页面推到更前位置。

基于这一观察，项目后期将视觉信息更多转移到生成阶段使用，实现了门控视觉辅助策略：仅在 `logo`、`pack text`、`heading`、`title`、`page number` 与短手写文本等题型上启用视觉辅助；对于 `chart`、`table`、一般数字题与抽象语义题则禁用该机制。该策略保留了视觉信息对局部短文本辨识的价值，同时避免其在不适合的题型上扰动文本证据主线。

门控视觉辅助的触发逻辑如算法 3 所示。

Algorithm 3 门控视觉辅助触发逻辑

Require: 用户问题 q ，顶部证据列表 $\mathcal{E}$ ，视觉辅助策略 $policy$

Ensure: 是否启用视觉辅助的布尔值 $flag$

- 1: 对 $policy$ 做归一化
 - 2: 若 $policy = \text{off}$ ，则返回 `False`
 - 3: 若 $policy = \text{always}$ ，则返回 `True`
 - 4: 对 q 做小写化与题型词检测
 - 5: 定义启用标记: `logo / brand / pack text / heading / title / page number / handwritten`
 - 6: 定义禁用标记: `chart / table / axis / amount / value / summary / abstract` 等
 - 7: 若 q 命中禁用标记，则返回 `False`
 - 8: 若 q 命中启用标记，则返回 `True`
 - 9: 若 q 较短，且顶部证据中存在 `page_image` 或 `figure` 类型证据，则返回 `True`
 - 10: 否则返回 `False`
-

4 实验设计

4.1 数据集与评测对象

本文主要围绕 DocVQA 进行系统性实验，并辅以 ChartQA 的流程验证。

其中，历史基准使用 DocVQA `val first-100`；后期主基准使用 `unique-docpage-100`。后者通过 `scripts/15_build_unique_docpage_benchmark.py` 从预处理后的 DocVQA 验证数据集出发，按 `(ucsf_document_id, ucsf_document_page_no)` 分组，保留每个文档页一个代表性问题，并结合 `question type` 做分层抽样，最终得到固定的 100 页

manifest。同步重建了 documents、chunks 与 indexes，从而形成与 manifest 严格对齐的 rebuilt corpus。

4.2 指标体系

本文采用的指标体系包括三类：

1. **检索指标：Hit@5 与 Precision@5**。其中，Hit@5 表示在系统返回的前 5 个证据块中，是否至少出现了一个与标准答案对应的正确证据；该指标主要衡量系统能否把正确页面或正确证据召回到候选集合中。Precision@5 表示前 5 个返回结果中相关证据所占的比例；该指标不仅关心“有没有找对”，也关心“候选列表中有多少噪声”，因此更能反映检索排序的纯度。
2. **引用指标：Citation@1**。该指标考察系统返回的第 1 条 citation 是否指向正确证据来源。在本文场景下，它比一般召回指标更严格，因为它直接对应用户最终最先看到的证据是否可信，因而可以近似衡量系统的 top-1 证据定位能力。
3. **回答指标：Exact Match、ANLS、Token-F1**，以及部分分析中使用的 Answer-Contains。其中，Exact Match 要求模型输出与标准答案在归一化后完全一致，适合衡量答案是否“严格答对”；ANLS (Approximate Normalized Levenshtein Similarity) 允许小幅字符差异，尤其适合 OCR 噪声、大小写差异或轻微拼写偏差较常见的文档问答场景；Token-F1 从词项重合角度综合考虑准确率与召回率，能够反映预测答案与标准答案在内容层面的整体接近程度；Answer-Contains 则用于补充分析，主要判断系统回答中是否至少包含标准答案的关键信息，适合观察回答虽然不完全规范、但是否已经抓住核心内容。

此外，src/evaluation/benchmark.py 中同时保留了 sample-level 与 doc-page-level 两种相关性判定逻辑。前者强调是否命中完全一致的样本来源，后者强调是否命中同一原始文档页。

4.3 对比实验设置

为分析系统演化中的真实收益，本文重点比较以下代表性实验线：

1. promptfix_v3：旧 benchmark 上较稳定的文本基线。
2. exp5_densefusion_w045：旧 benchmark 上表现最好的视觉稠密融合线。
3. stronger_rebuilt：修复 benchmark 后的文本优先重排主线。
4. stronger_qia_v6：加入 query-image-aware rerank 后的当前最佳检索线。

5. `stronger_qia_base`: 修复 benchmark 后的 clean grounding-first RAG 基线。
6. `stronger_qia_visualassist_gated_v2`: 当前最佳端到端主线。

5 实验诊断与策略调整

本章仅保留影响后续结果解释的两个关键诊断，其余细节放入结果分析中统一讨论，以避免重复叙述。

5.1 评测协议修复与 rebuilt corpus

误差分析表明，原始 DocVQA val first-100 虽包含 100 个 QA 样本，但只对应 29 个唯一文档页。许多 sample 共享同一原始页面，使 sample-level 指标难以区分“没有找到正确页面”与“找到了同页但不是当前副本”。为此，项目构建了 `unique-docpage-100` 固定评测清单，并同步重建与其对齐的 `documents`、`chunks` 与 `indexes`，从而保证评测对象、索引对象与证据定义保持一致。

5.2 从检索期视觉融合到生成期视觉辅助

在修复 benchmark 后，项目发现两个结论逐步稳定下来。其一，`fallback_text` 这类问题回声块会劫持 top-1 排序，因此检索主线的首要改进应是强化文本优先重排，压制低信息词与模板复述。其二，视觉稠密融合并未在检索阶段带来稳定收益，反而更适合在生成阶段作为局部视觉补偿模块使用。基于这一认识，系统最终收敛为以文本优先检索为主线、以门控视觉辅助为补充的结构，后文将围绕这一主线给出结果分析。

6 实验结果与分析

本节围绕各个模块带来的收益与负面效果进行组织。第一，benchmark 修复首先校正了系统比较的基础；第二，修复后的主要检索增益来自文本优先排序，而非更早的多模态融合；第三，视觉信息更适合作为生成阶段的局部补偿，而不是检索阶段的默认主线。

6.1 评测基准修复

在原始 DocVQA val first-100 上，旧文本基线与旧视觉稠密融合线的差距很小，如表 2 所示。

这些数字容易给人留下“更强视觉融合略优”的印象。然而这一比较并不可靠，因为旧基准混入了大量重复页，sample-level 打分无法真实反映系统是否已经找到正确文

表 2: 原始基准上的历史结果

line	setting	Hit@5	Precision @5	Citation @1	EM
promptfix_v3	retrieval	0.49	0.114	0.12	–
exp5_densefusion_w045	retrieval	0.51	0.118	0.13	–
promptfix_v3	rag	0.49	0.114	0.12	0.78
exp5_densefusion_w045	rag	0.51	0.118	0.13	0.77

档页。因此，这一阶段结果的主要价值不是比较方法优劣，而是暴露评测协议本身存在偏差。

在修复为 `unique-docpage-100` 并重建对应索引语料之后，检索结果发生了结构性变化，如表 3 所示。

表 3: 修复基准后的检索结果

line	概述	Hit@5	Precision @5	Citation @1
stronger_rebuilt	修复基准后的文本优先主线	0.93	0.19	0.89
stronger_qia_v6	加入图像感知重排的检索主线	0.95	0.196	0.91
exp5_rebuilt	修复基准后的视觉融合线	0.93	0.19	0.88

基准修复后，文本优先主线反而优于此前看似更有前景的视觉稠密融合线。因此，后文关于各模块贡献的讨论均以修复后的 `unique-docpage-100` 为准。这里最重要的结论是：benchmark 修复首先改变的是”系统被如何测量”，然后才谈得上”系统被如何比较”。

6.2 文本优先排序

在统一基准上，页级文本、块级文本与块级多模态索引的表现几乎一致，说明当前性能提升并不是靠改变索引颗粒度或索引表示获得的，而主要取决于检索排序本身是否能够把正确证据放到前列。

进一步看检索增强链路的消融，如表 4 所示。

表 4: 检索增强链路消融实验

retrieval line	概述	Hit@5	Citation @1	DocPage Hit@5
basic	基础文本检索	0.93	0.89	0.93
stronger	强化文本重排	0.95	0.90	0.95
stronger + qta	强化文本重排加题型感知重排	0.95	0.90	0.95
stronger + qia	强化文本重排加图像感知重排	0.95	0.91	0.95

从这组结果可以把不同模块的作用拆开来看。`basic` -> `stronger` 是检索链路中最主要的一步提升：Hit@5 从 0.93 提高到 0.95，Citation@1 从 0.89 提高到 0.90。这

一提升主要来自更稳健的文本优先排序，包括削弱低信息词干扰、抑制问题回声块、以及改进候选重排逻辑，把排序对象重新拉回到”真实页面证据”。

相比之下，query-type-aware rerank 在当前子集上的额外增益较小，说明题型启发式在这一固定样本集上更多扮演”稳定器”而不是”主要增长点”。而 query-image-aware rerank 虽未继续提高 Hit@5，却把 Citation@1 从 0.90 推高到 0.91，说明它更主要地改善了 top-1 证据排序，而不是扩大候选召回范围。也就是说，检索链路中的核心增益来自文本优先主线本身，后续视觉感知重排只提供了相对有限但方向明确的补充。

6.3 视觉信息前置到检索阶段

为了检验”更强多模态检索”是否真的优于文本优先主线，本文进一步比较了文本优先主线与 retrieval-time dense fusion，如表 5 所示。

表 5: 检索阶段视觉融合对比

line	概述	Hit@5	Citation @1	DocPage Hit@5
stronger + qia	文本优先加图像感知重排主线	0.95	0.91	0.95
visual_densefusion	检索阶段视觉稠密融合	0.95	0.79	0.95

这是一组非常关键的负结果。视觉稠密融合并没有降低页级召回，Hit@5 仍保持 0.95；但它显著破坏了 top-1 证据排序，使 Citation@1 从 0.91 下降到 0.79。这说明视觉信息在当前课程文档场景下并非”越早介入越好”。对于布局近似、模板重复、视觉元素高度相似的页面，视觉描述符更容易把”相似页”排到前面，而不一定把真正含有答案的证据页排到前面。

因此，视觉模块在检索阶段带来的并不是稳定增益，而是一个明确的风险：它可能保住了”找对页”的能力，却损害了”把最正确的证据放在第一位”的能力。对以 citation 为核心的文档问答系统而言，这种负面效果比单纯召回下降更值得警惕。

6.4 视觉信息放到生成阶段后

在确认视觉稠密融合不适合作为检索主线后，项目将视觉信息转移到生成阶段，并区分两种评测口径。第一种是 Corpus-grounded RAG：模型不能直接看题图，必须依赖语料库中的页面证据作答；第二种是 Query-image assisted QA：允许模型直接观察 query page image，用于估计视觉识别上限。前者支撑主结论，后者仅作补充诊断。

先看 Corpus-grounded RAG。如表 6 所示，各条实验线的 Hit@5 与 Citation@1 基本保持不变，因此差异主要来自生成阶段是否成功利用视觉证据。cg_text_only 只有 EM=0.13，而 cg_visualassist_always 提升到 EM=0.82、ANLS=0.834982、Token-F1=0.839753，说明视觉辅助对局部短文本、标题、页码和手写短语等问题具有决定性价值。

但这组结果也同时暴露出当前门控策略的不足。cg_visualassist_gated 虽优于 cg_text_only，却仅达到 EM=0.20，与 always 之间仍有巨大差距。这意味着问题不在于“视觉有没有用”，而在于“现有 gate 过于保守，没有把视觉能力在该用的时候及时调动起来”。

为进一步验证这一判断，表 6 对不同 gate 版本进行了细拆。

表 6: 不同门控策略的对比

gate policy	概述	Hit@5	Citation @1	EM	ANLS	Token- F1
cg_text_only	仅用语料文本证据作答	0.95	0.90	0.13	0.13	0.147952
cg_logo_only	仅在徽标题触发视觉辅助	0.95	0.90	0.16	0.16	0.176928
cg_title_page_only	仅在标题与页码触发视觉辅助	0.95	0.90	0.18	0.195627	0.206292
cg_handwritten_only	仅在手写题触发视觉辅助	0.95	0.90	0.14	0.14	0.157448
cg_visualassist_gated	统一门控视觉辅助	0.95	0.90	0.20	0.20	0.216080
cg_visualassist_always	始终启用视觉辅助	0.95	0.90	0.82	0.834982	0.839753

可以看到，无论是单独题型门控，还是统一启发式门控，都只带来了有限提升；真正的大幅改善来自 always。因此，生成阶段视觉辅助本身是有效模块，但当前“是否触发”的策略仍是系统最薄弱的部分。换言之，视觉模块的正贡献已经被实验充分证明，真正限制其收益释放的，是 gate 设计，而不是视觉信息本身。

6.5 模型的视觉能力不是主要瓶颈

作为补充，在 Query-image assisted QA 设定下，各种配置几乎都稳定在 EM 0.93、ANLS 0.946。这说明模型本身并不缺少基本视觉识别能力，系统真正的瓶颈在于 corpus-grounded 条件下如何把视觉能力与语料库证据稳定连接起来。换言之，问题主要出在视觉证据的触发与组织，而不是模型“看不懂图”。




图 2: Grounding 与回答质量的整体权衡。

图 2 汇总了历史 mixed setting、Corpus-grounded RAG 与 Query-image assisted QA 三种口径下的代表性实验点。可以看到, qiaqa_* 点虽然回答质量较高, 但 grounding 指标为零; 而 cg_* 点则体现了”证据可追溯”与”回答质量”之间的真实工程张力。

6.6 本章小结：各模块的真实贡献与代价

综合本章结果, 可以将各模块作用概括为四点:

1. 评测基准修复带来的不是普通参数提升, 而是对系统真实能力的重新测量; 它决定了后续结论是否可信。
2. 检索链路中, 最主要的正向贡献来自更稳健的文本优先排序; 题型感知和 query-image-aware 重排只提供了有限但有方向性的补充。
3. 视觉信息若前置到检索阶段, 会明显损害 top-1 citation 排序, 因此不适合作为当前系统的默认主线。
4. 视觉信息若后置到生成阶段, 则能显著提升回答质量; 但当前门控策略过于保守, 尚未充分释放这一模块的真实收益。

7 讨论

7.1 相比开题设想的真实变化

开题报告中的系统设想更接近”结构化切分 + 双路径 RAG + 晚融合”的典型多模态方案。结题阶段表面上仍保留了这一框架, 但其内部逻辑已经发生重要变化: 系统不再默认认为”多模态越早介入越好”, 而是通过实验逐步建立了更细化的角色分配, 即文本路径负责主证据排序, 视觉路径负责局部识别补偿, benchmark 修复负责保障实验可解释性。

这种变化说明, 项目的成熟并不只体现在功能变多或分数升高, 更体现在系统主次关系的认识更加清晰。相比”证明某个模块有用”, 本文更重要的贡献在于澄清”该模块在什么条件下、以什么方式有用”。

7.2 本项目最值得保留的研究经验

从研究方法角度看, 本项目最值得保留的经验主要有三点。

第一, benchmark 并不是中性的。若评测对象与真实任务目标不一致, 分数既可能夸大问题, 也可能掩盖真实进步。第二, 多模态信息不是天然正增益。其有效性取决于介入时机、题型条件与系统中的证据角色。第三, 工程闭环与科学诊断同等重要。只有当 schema、API、citation、评测脚本与误差分析被统一到同一框架内, 实验现象才真正具备可解释性。

如果进一步概括，这三条经验实际上共同指向一个更一般的研究原则：对于工程型多模态系统，真正高质量的结题工作不应仅展示”做成了什么”，更应解释”为何这样做、为何此前的做法不够好、以及结论为何值得相信”。

8 局限性与后续工作

尽管当前系统已形成较完整的离线评测闭环，但仍存在以下局限。

1. 当前主要结论建立在 DocVQA 风格数据上，`unique-docpage-100` 虽比旧基准更合理，但仍属于固定切片，外部泛化能力仍需在更多文档域上验证。
2. 当前检索优化仍包含较强启发式成分，虽然在课程项目中有效，但未必能无缝推广到更大规模开放域语料。
3. 当前 benchmark 主要衡量页级检索与页级 grounding，而非更细粒度的区域级定位；页面正确不等于区域必然正确。
4. 在线文件上传、增量解析、实时建索引与长期 workspace 管理尚未成为正式实验对象，系统当前更接近研究原型而非完整产品。

据此，后续工作可沿三条路线展开：

1. 推进在线文档接入与增量索引，使系统从离线 benchmark 原型进一步走向真实交互应用。
2. 在现有 query-aware rerank 的基础上引入更学习化的页级或区域级 reranker，提升 generic/deictic query 的 grounding 能力。
3. 结合不确定性估计进一步细化视觉辅助门控策略，仅在模型对局部视觉短文本存在明显识别困难时触发视觉补偿。

9 结论

本文围绕课程文档场景下的多模态问答任务，完成了一套以块优先结构、可追溯引用与 benchmark 驱动诊断为核心的多模态 RAG 系统实现与实验分析。与开题阶段相比，结题阶段最重要的进展并不只是”做出了一个能运行的系统”，而是通过一系列失败分析、评测修复与实现重构，澄清了系统中真正的主要矛盾。

研究结果表明，原始 DocVQA val first-100 上看似持久的性能平台期，在很大程度上来自 benchmark 的重复页污染；在构造 `unique-docpage-100` 并重建对应索引语料后，文本优先检索能力得到了更真实的反映。同时，视觉信息虽然对页面理解不可或

缺，但其最有效的系统角色并不是默认前置到检索排序，而是在文本证据已经稳定的前提下，以题型敏感的方式辅助生成模型完成局部视觉辨识。

因此，本文最终给出的判断：对于课程规模的多模态文档问答系统，评测对象与索引对象的一致性、文本优先的稳定检索主线，以及题型敏感的门控视觉辅助机制，比简单堆叠更多多模态融合模块，更能带来可信、可解释且可复现的系统提升。

参考文献

- [1] M. Suri, P. Mathur, F. Deroncourt, *et al.*, “Visdom: Multi-document qa with visually rich elements using multimodal retrieval-augmented generation,” in *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pp. 6088–6109, 2025.
- [2] Y. Shi, C. Tang, B. Xu, *et al.*, “Visrag: Vision-based retrieval-augmented generation on multi-modality documents,” *arXiv preprint arXiv:2410.10594*, 2024.
- [3] Y. Huang, T. Lv, L. Cui, *et al.*, “Layoutlmv3: Pre-training for document ai with unified text and image masking,” *arXiv preprint arXiv:2204.08387*, 2022.
- [4] J. Cho, D. Mahata, O. Irsoy, *et al.*, “M3docrag: Multi-modal retrieval is what you need for multi-page multi-document understanding,” *arXiv preprint arXiv:2411.04952*, 2024.
- [5] M. Mathew, D. Karatzas, and C. V. Jawahar, “Docvqa: A dataset for vqa on document images,” *arXiv preprint arXiv:2007.00398*, 2020.
- [6] A. Masry, D. X. Long, J. Q. Tan, *et al.*, “Chartqa: A benchmark for question answering about charts with visual and logical reasoning,” in *Findings of the Association for Computational Linguistics: ACL 2022*, pp. 2263–2279, 2022.
- [7] Microsoft, “harrier-oss-v1-270m,” 2024. [EB/OL].
- [8] Microsoft, “harrier-oss-v1-0.6b,” 2024. [EB/OL].
- [9] Qwen, “Qwen3-vl-embedding-2b,” 2026. [EB/OL].
- [10] OpenDataLab, “Mineru: A unified and efficient solution for high-quality document content extraction,” *arXiv preprint arXiv:2409.18839*, 2024.