

多模态文档理解与检索问答系统开题报告

陈宝怡 23336029 孙韵淇 23336215 吴承徽 23336247

2026 年 5 月 6 日

1 引言

1.1 研究背景

在教育学习、学术研究及日常办公场景中，PDF 讲义、PPT 截图、扫描文档等课程相关文档广泛存在，这类文档通常融合了文本、表格、图表、公式等多种模态信息，且具有复杂的视觉排版特征。在期末复习、知识点检索等场景下，用户往往需要在海量多页文档中快速定位关键信息，传统基于关键词匹配或纯文本检索的方法已难以满足实际需求。

当前文档理解与问答系统面临的核心瓶颈是语义丢失与长文本检索困难两大问题。其中语义丢失主要体现在三个方面：一是纯文本提取过程中，图表、公式等非文本模态信息被完全丢弃，导致视觉语义缺失；二是文档切分采用忽略语义的硬切分方式，易造成跨页、跨语义块的信息断裂，检索时仅能召回部分相关信息；三是布局缩进、标题层级、栏位关系等空间布局语义被忽略，导致文档内容碎片化，破坏了原本的语义关联。此外，长文档的上下文长度限制与计算成本问题，进一步加剧了检索与问答的难度，无法实现高效、精准的知识点查询。

随着多模态大模型(Vision-Language Models, VLM)与检索增强生成(Retrieval-Augmented Generation, RAG)技术的快速发展，同时理解视觉与语言信息、突破长文本处理限制成为可能。然而，直接将整本文档输入 VLM 存在上下文长度不足与计算开销过大的问题，而传统 RAG 框架又往往忽略文档的视觉布局与多模态语义，难以兼顾检索效率与答案准确性。因此，构建结合文档结构感知与多模态检索增强的问答系统，解决语义丢失与长文本检索问题，具有重要的理论研究价值与实际应用意义。

1.2 研究目标与核心任务

本研究旨在构建一个面向课程文档(PDF 讲义、PPT 截图等)的多模态智能问答系统，实现对多模态文档的结构化解析、精准检索与高效问答，具体核心任务包括：

- 文档结构化解析：对输入的多页 PDF、扫描文档或 PPT 截图进行版面分析，精准提取文本、表格、图像、公式等不同模态内容，并保留其空间布局位置信息；
- 多模态索引构建：采用语义化切分策略，对不同模态内容进行向量化表示，构建文本与视觉双模态索引，支持高效检索；

- 自然语言问答：支持用户自然语言问题输入，结合多模态检索结果与 VLM 的推理能力，生成准确、完整的答案，并标注答案来源（页码或图号），实现可追溯；
- 性能评测与分析：在标准数据集与自建场景数据集上完成系统评测，对比多模态 RAG 与纯文本 RAG 的效果差异，分析系统错误来源并提出优化方向。

2 相关工作

2.1 多模态大模型（VLM）在文档理解中的应用

多模态大模型是文档多模态理解的核心基础，其能够同时处理文本与视觉信息，实现对文档中复杂模态内容的语义理解。目前，面向文档理解的 VLM 已取得显著进展，其中 Qwen-VL 系列模型表现突出，Qwen3-VL-8B-Instruct 与 Qwen3-VL-4B-Instruct 在 DocVQA 数据集上分别达到 96.1 与 95.3 的准确率，是同参数量级下的 SOTA 模型。此外，InternVL、LLaMA 3.2 Vision、DeepSeek-VL 等模型也具备较强的文档处理能力，能够精准识别文档中的文本、表格与图像区域，理解其语义关联。

现有 VLM 的优势在于能够有效捕捉文本与视觉的跨模态语义，但局限性也较为明显：多数模型仅适用于单页文档的端到端推理，无法直接处理多页长文档，且缺乏与检索机制的深度融合，难以应对长文档的上下文管理，这也是本研究需要解决的核心痛点之一。

2.2 检索增强生成（RAG）技术的发展与应用

RAG 技术通过将检索与生成相结合，有效解决了大模型上下文长度限制与知识时效性问题，成为长文档问答的主流技术路径。传统 RAG 主要基于纯文本检索，通过 OCR 提取文档文本后进行分块、向量化索引，再结合文本生成模型生成答案，但这种方式完全丢失了图表、公式等视觉模态信息，无法应对多模态文档的理解需求。

近年来，多模态 RAG 技术快速发展，其中 VisDoM 与 VisRAG 是具有代表性的框架 [1,2]。VisDoM 提出双路 RAG+ 晚融合策略，并行构建视觉与文本两条检索通路，通过证据筛选、思维链推理后，由 LLM 调和两种模态的推理结果，生成最终答案，实验表明该框架比纯视觉 RAG 性能提升明显 [1]。VisRAG 则采用 VLM 直接对文档页面进行图像嵌入，通过计算查询与文档页面的相似度实现检索，再通过页面拼接、加权选择或多图输入等方式处理多页面信息，有效保留了文档的视觉语义 [2]。

此外，M3DocRAG 框架面向多页多文档场景，采用 ColPali 模型进行细粒度视觉嵌入，结合 Faiss 索引提升检索效率，实验验证其在图表密集文档上的性能显著优于纯文本 RAG，但其采用整页作为检索粒度，易引入无关噪声，降低答案精准度 [4]。这些研究为本文双路 RAG 架构的设计提供了直接的技术参考，同时也指出了现有多模态 RAG 在检索粒度与语义保留方面的改进空间。

2.3 文档结构感知与多模态表征

文档的空间布局信息是语义理解的重要组成部分，传统文档处理方法往往忽略布局语义，导致语义丢失。LayoutLMv3 作为文档 AI 领域的经典预训练框架，提出了统一的文本与图像掩码策略，通过线性投影的图像 Patch 作为视觉输入，降低计算开销，同时引入 Masked Image Modeling (MIM) 与词-块对齐 (WPA) 目标，强制模型学习文本与视觉的细粒度关联，有效提升了文档布局理解与跨模态对齐能力 [3]。

实验表明，LayoutLMv3 在表单理解、收据理解、文档分类等任务上均取得了优异性能，其“无 CNN”的轻量化设计的思路，也为资源受限场景下的文档解析提供了可行路径。该研究揭示了文档的二维空间结构对语义理解的重要性，为本研究的文档结构化解析与语义分块模块提供了核心理论启发，指导我们在解析过程中不能忽略视觉外观与布局位置信息。

2.4 语义化文档切分技术

文档切分是 RAG 技术的基础，传统硬切分方式存在语义断裂、阅读顺序错乱、布局语义丢失等问题，严重影响检索与问答性能。MinerU 等语义化切分工具能够基于文档的布局结构与语义关联，实现文本块、图像、表格的智能切分，有效避免硬切分导致的语义丢失，同时保持文档的阅读顺序与语义完整性。

相关研究表明，采用语义化切分能够显著提升检索的召回率与准确率，尤其在图表密集、双栏排版的文档场景中，优势更为明显。这为本文解决硬切分导致的语义丢失问题提供了关键技术支撑，通过引入语义化切分工具，实现文档的精细化、语义化分块，为后续多模态索引构建与检索奠定基础。

2.5 相关工作总结与不足

现有研究已验证了 VLM 在单页文档理解中的有效性、多模态 RAG 在长文档处理中的优势，以及文档结构感知与语义化切分对语义保留的重要性。但综合来看，现有工作仍存在以下不足：一是多数多模态 RAG 框架采用粗粒度的整页检索，易引入无关噪声，影响答案精准度；二是部分框架忽略布局语义与语义化切分，仍存在语义丢失问题；三是缺乏可追溯的答案引用机制，降低了系统的可信度与实用性；四是针对课程文档这一封闭域场景的优化不足，难以满足学生的实际检索需求。本研究将针对上述不足，结合现有技术优势，设计更贴合实际应用场景的多模态 RAG 系统。

3 方法

3.1 总体设计思路

针对语义丢失（纯文本提取、硬切分、布局忽略导致）与长文本检索困难两大核心问题，本研究采用“语义化切分 + 双路 RAG + 晚融合”的总体方案，结合 MinerU 语义切分工具、多模态嵌入模型与 VLM 推理能力，构建多模态文档理解与检索问答系统。整体流程分为四

个阶段：文档解析与语义切分、多模态索引构建、双路并行检索推理、晚融合与答案生成，各阶段紧密衔接，针对性解决核心问题。

3.2 核心模块设计

3.2.1 文档解析与语义化切分模块

本模块的核心目标是解决硬切分导致的语义丢失、布局信息忽略等问题，实现文档的精细化、语义化解析。具体流程如下：

- 语义化切分：引入 MinerU 工具，基于文档的布局结构（标题层级、栏位关系、图文位置关联）与语义关联，将文档切分为文本块、表格块、图像块等语义单元，避免跨语义块的硬切分，同时保持文档的阅读顺序与语义完整性；
- 模态标注与结构化存储：对每个语义单元进行模态标注（图像、表格等），关联其页码、图号等来源信息，构建统一的结构化数据格式，为后续多模态索引构建提供基础。

3.2.2 多模态索引构建模块

本模块旨在构建文本与视觉双模态索引，解决纯文本检索导致的视觉语义丢失问题，提升检索的精准度与召回率。具体设计如下：

- 文本嵌入与索引：采用 Microsoft Harrier-oss-v1 系列模型作为文本嵌入模型 [7,8]，该模型在 MTEB 检索指标上表现优异，支持多语言处理，能够生成具有强语义表征能力的文本向量。对切分后的文本块进行向量化编码，存入 ChromaDB 本地轻量级向量库；
- 视觉嵌入与索引：采用 Qwen3-VL-Embedding-2B 作为图像嵌入模型 [9]，该模型在 MMEB-Leaderboard 上表现突出，支持多模态输入，能够生成精准的视觉语义向量。对切分后的图像块、表格块、公式块进行视觉向量化编码，同样存入 ChromaDB，构建视觉索引；

3.2.3 双路 RAG 并行检索推理模块

本模块参考 VisDoM 与 VisRAG 的设计思路 [1,2]，构建视觉与文本双路并行检索推理通路，解决长文本检索困难与单模态检索的局限性，具体流程如下：

- 查询解析：对用户输入的自然语言问题进行解析，识别问题类型（如文本查询、图表查询、公式查询），提取关键信息，生成适配双路检索的查询向量；
- 文本 RAG 通路：基于文本查询向量，在文本索引中检索 Top-K 相关文本块，将问题与检索到的文本块输入 VLM (Qwen3-VL-8B-Instruct)，执行证据筛选、思维链推理，生成文本模态的初步答案与推理链；
- 视觉 RAG 通路：基于查询向量，在视觉索引中检索 Top-K 相关视觉块（图像、表格、公式），参考 VisRAG 的处理方式，将视觉块与问题输入 VLM，执行证据筛选、思维链推理，生成视觉模态的初步答案与推理链；

- 推理链优化：对两条通路的推理链进行初步整理，去除冗余信息，标注每个推理步骤对应的来源（页码、图号），为后续晚融合提供清晰的推理依据。

3.2.4 晚融合与答案生成模块

本模块通过晚融合策略，调和双路检索推理的结果，解决模态间的一致性问题的，生成准确、完整且可追溯的最终答案。首先，进行一致性检测，将双路通路的推理链与初步答案输入 LLM，检测两者的一致性，识别是否存在矛盾或互补信息；对一致的信息进行整合，对矛盾的信息进行验证，对互补的信息进行融合，确保最终答案的准确性与完整性；在最终答案中，标注每个关键信息对应的来源（页码、图号），实现答案的可追溯，提升系统的可信度；

3.3 技术栈选择

基于系统设计需求与算力限制（1×24GB GPU 或云端 API），选择以下技术栈，确保系统的可行性与高效性：

- 多模态大模型：Qwen3-VL-8B-Instruct、Qwen3-VL-Embedding-2B；
- 文本嵌入模型：Microsoft Harrier-oss-v1-270m / harrier-oss-v1-0.6b；
- 文档解析与切分：PaddleOCR（用于对比纯文本 RAG 的效果）、MinerU（语义化切分）；
- RAG 框架与向量库：LlamaIndex、ChromaDB；

4 测评

4.1 数据集选择与预处理

为全面评估系统性能，兼顾标准性与实际应用场景，选择三类数据集进行测评：

4.1.1 DocVQA 数据集

DocVQA 是文档图像视觉问答的经典基准数据集 [5]，来源于真实文档库，包含 12000 余张文档图像与 50000 余个问答对，文档包含复杂排版结构（段落、表格、表单、图表等），问题类型涵盖表格理解、布局推理、图表理解等，能够有效评估系统的多模态理解与问答能力。

4.1.2 ChartQA 数据集

ChartQA 数据集专注于图表场景下的问答任务 [6]，包含大量柱状图、折线图、饼图等图表图像与对应的问答对，70% 以上的问题涉及视觉理解与逻辑推理，能够重点评估系统对图表模态的理解与推理能力。

4.1.3 自建课程文档数据集

为验证系统在真实课程学习场景中的可用性，收集日常课程讲义、PPT 课件、课程作业等文档，人工构建问答对，重点包含跨页总结、图表与公式结合的问题，模拟学生期末复习中的实际检索需求。

4.2 评测指标

结合检索与生成两个核心阶段，设置以下评测指标，全面评估系统性能，同时对比多模态 RAG 与纯文本 RAG 的效果差异：

4.2.1 检索阶段指标

- Recall@K (召回率)：前 K 个检索结果中包含真实答案所在语义块的查询比例，用于衡量系统检索的召回能力，重点评估语义化切分与多模态索引的有效性；
- Precision@K (精确率)：前 K 个检索结果中与查询相关的语义块比例，用于衡量系统检索的精准度，避免无关信息的召回。

4.2.2 生成阶段指标

- ANLS (Average Normalized Levenshtein Similarity)：DocVQA 数据集的核心评测指标，能够宽容 OCR 错误导致的轻微答案不匹配，客观反映答案的准确性；
- Accuracy (准确率)：设置严格与宽松两个标准，非数值型事实答案要求完全一致，图表推理类答案允许合理误差，用于评估答案的精准度；
- 引用准确率：评估答案中标注的页码、图号与真实来源的一致性，衡量可追溯性；

4.3 评测方案与预期结果

4.3.1 评测方案

- 基线模型：纯文本 RAG (采用相同的文本嵌入模型与 RAG 框架，仅对文本进行检索与推理，忽略视觉模态信息)；
- 实验分组：纯文本 RAG 组、本研究多模态 RAG 组 (无语义化切分)、本研究多模态 RAG 组 (有语义化切分)，对比分析语义化切分与多模态融合的作用；
- 错误分析：收集系统生成的错误答案，分类统计错误类型 (检索错误、模型幻觉、融合错误)，分析错误原因并提出优化方向。

4.3.2 预期结果

- 功能层面：系统能够正常支持多页 PDF、图像的上传与解析，实现语义化切分、多模态检索与问答，生成带可追溯引用的答案；
- 性能层面：在 DocVQA 数据集上，系统 ANLS 指标 $\geq 60\%$ ；多模态 RAG 相比纯文本 RAG，各项指标提升 $\geq 10\%$ ；语义化切分能够使检索召回率提升 $\geq 5\%$ ；
- 分析层面：明确系统主要错误来源，验证双路 RAG+ 晚融合 + MinerU 策略对语义丢失与长文本检索问题的解决效果。

参考文献

- [1] Suri M, Mathur P, Deroncourt F, et al. VisDoM: Multi-Document QA with Visually Rich Elements Using Multimodal Retrieval-Augmented Generation[C]// Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2025: 6088-6109.
- [2] Shi Y, Tang C, Xu B, et al. VisRAG: Vision-based Retrieval-augmented Generation on Multi-modality Documents[J]. arXiv preprint arXiv:2410.10594, 2024.
- [3] Huang Y, Lv T, Cui L, et al. LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking[J]. arXiv preprint arXiv:2204.08387, 2022.
- [4] Cho J, Mahata D, Irsoy O, et al. M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding[J]. arXiv preprint arXiv:2411.04952, 2024.
- [5] Mathew M, Karatzas D, Jawahar C V. DocVQA: A Dataset for VQA on Document Images[J]. arXiv preprint arXiv:2007.00398, 2020.
- [6] Masry A, Long D X, Tan J Q, et al. ChartQA: A Benchmark for Question Answering about Charts with Visual and Logical Reasoning[C]// Findings of the Association for Computational Linguistics: ACL 2022. 2022: 2263-2279.
- [7] Microsoft. harrier-oss-v1-270m[EB/OL]. <https://huggingface.co/microsoft/harrier-oss-v1-270m>, 2024.
- [8] Microsoft. harrier-oss-v1-0.6b[EB/OL]. <https://huggingface.co/microsoft/harrier-oss-v1-0.6b>, 2024.
- [9] Qwen. Qwen3-VL-Embedding-2B[EB/OL]. <https://huggingface.co/Qwen/Qwen3-VL-Embedding-2B>, 2026.